

电商商品销量预测与促销效果分析项目中期进展报告

项目阶段： 阶段二（实施与中期）

当前状态： 已完成数据清洗与初步分析，基线模型已成功跑通。

报告人：孙一轩、黄俊凯、邓时峰、张云飞

一、 数据基础概况与预处理

本项目采用经过完整预处理的数据集 `cleaned_data.csv`。前期已对原始数据进行系统化清洗，主要操作包括：

缺失值处理：剔除所有含有空值的记录。

异常值过滤：基于 3σ 原则及业务逻辑对不合理的销量（如负值、极端离群值）进行过滤。

数据量级：预处理后保留有效建模样本共计 1,188,323 条。

特征名称	数据类型	含义说明	样本平均值
Price	Float	商品单价（自变量）	750.42
Sales	Float	商品销量（因变量）	35,000.15

二、 探索性数据分析 (EDA)

2.1 销量分布特征分析

为探究商品整体销量的分布规律，项目组绘制了销量分布直方图（如图一）。结果显示，商品销量呈现明显的右偏分布(Long-tail Distribution)。绝大多数商品的销量集中在较低区间，而爆款商品（高销量样本）占比较小。这符合电商平台“长尾效应”的业务现状，同时也提示在模型训练中需要注意对极端值的处理。

2.2 价格与销量的关联性挖掘

由于样本量巨大，项目组采用六边形密度热力图 (Hexbin Plot)（如图二） 解决散点重叠问题。从可视化结果可以清晰看出：


- 高密度区：集中在低价区间，对应商品销量普遍偏高。
- 变化趋势：随着单价升高，高销量样本的密度显著降低。 这一现象印证了需求曲线的基本规律：价格与销量存在明显的负相关。

2.3 特征相关性量化校验

通过计算 Pearson 相关系数，我们对变量间的关联程度进行了定量评估：

Price 与 Sales 的相关系数为：-0.4562 结果显示两者呈中度负相关。这从量化层面验证了前文可视化分析得出的结论，确立了“价格”作为销量预测核心特征的地位。

附图表：



图一

图二

三、 模型设计思路与基线实验

3.1 模型设计方案

鉴于目前的特征维度（主要为数值型），项目组制定了“由简入深”的开发策略：

1. 基线模型(Baseline): 使用线性回归(Linear Regression)验证数据最基础的预测潜能。
2. 特征工程提升: 在下一阶段引入日期（节假日）、店铺类型(Store_Type)类别特征。
3. 非线性建模: 尝试引入随机森林(Random Forest)或 XGBoost 算法，以捕获更复杂的市场波动趋势。

3.2 基线模型初步表现

目前已完成基于 Scikit-learn 的基线实验，采用 8:2 的比例划分训练集与测试集。初步实验显示模型能反映基本趋势，但在处理爆款商品的波峰预测时仍有优化空间。

四、 遇到的问题及解决方案

1. 数据长尾分布偏差: 极少数极高销量样本对模型损失函数影响较大。

方案: 后续计划对 Sales 目标变量进行对数变换(Log Transform)以平滑分布。

2. 特征维度受限: 目前仅靠价格特征，模型的解释性有限。

方案: 已在原始数据中挖掘出节假日、折扣标识等隐含特征，计划进行 One-hot 编码处理并加入模型。